

Introduction au traitement automatique des langues

RCP 217

Serge Rosmorduc
`serge.rosmorduc@lecnam.net`
Conservatoire National des Arts et Métiers
Cédric, équipe Vertigo

2020–2021

Représentation des mots

Qu'est-ce qu'un mot

- ▶ Une entrée dans le dictionnaire ? (et les mots inconnus ?)
- ▶ une suite de lettre ?
 - ▶ Sprachverarbeitungsprozesse (Sprach/verarbeitungs/prozesse = traitement des langues)
 - ▶ pomme de terre
 - ▶ aujourd'hui
 - ▶ S.N.C.F.
- ▶ sens des mots

WordNet

- ▶ Graphe hiérarchisé de mots librement disponible ; très utilisé en TAL « pré-connexionniste » ;
- ▶ Une entrée dans WordNet est un "synset" - un ensemble de quasi-synonymes
- ▶ Wordnet fournit des relations entre les mots : sorte-de, partie-de, etc.
- ▶ Reste assez rigide - comment représenter un "glissement" sémantique ?
- ▶ Les mots rentrent-ils toujours dans une hiérarchie ?

La représentation des mots, « one-hot »

Comment représenter un mot dans un réseau de neurones ?

- ▶ solution immédiate : on associe à chaque mot un indice entier arbitraire ;
- ▶ on préfère un codage binaire :

0	1	2	...	$i-1$	i	$i+1$	...	n_v
0	0	0	0	0	1	0	0	0

- ▶ fonctionne...
- ▶ le mot i et le mot $i+1$ du dictionnaire n'ont a priori aucun rapport entre eux...
- ▶ mais la distance entre deux mots est toujours de $\sqrt{2}$... on aimerait que $||\text{chat}, \text{chien}|| < ||\text{chat}, \text{calculer}||$
- ▶ représentation creuse « sparse ».

Marqueurs supplémentaires

- ▶ Dans le vecteur one-hot, on a des "pseudo" mots
- ▶ <UNKNOWN> pour les mots inconnus
- ▶ <PADDING> pour le padding
- ▶ si le vocabulaire n'est pas tiré du corpus d'entraînement, on aura naturellement des occurrences de UNKNOWN dans l'entraînement ;
- ▶ sinon, les simuler, en remplaçant aléatoirement des mots peu fréquents du corpus par UNKNOWN.
- ▶ éventuellement, un marqueur de début de phrase et un marqueur de fin de phrase

Sémantique distributionnelle

- ▶ *You shall know a word by the company it keeps* (Firth, J. R. 1957 :11) ;
- ▶ Le sens d'un mot, ce sont les **contextes** dans lesquels il peut apparaître ;
- ▶ notion de *concordance* chez les linguistes et les philologues ;
- ▶ idée : trouver une représentation du mot qui soit fonction de ses contextes ;
- ▶ premier essais 1992, Brown *et al*, « Class-based n-gram models of natural language », Computational Linguistics, 18(4) :467–479.

Word Embedding


- ▶ Représentation vectorielle "pleine" et de petite dimension (50-300) d'un mot ;
- ▶ on espère que deux mots sémantiquement proches auront des représentations proches ;
- ▶ premières approches (non connexionnistes) : *Latent Semantic Analysis* ;

Word2Vect

- ▶ Apprentissage *non supervisé* de représentations vectorielles de mots ;
- ▶ Tâche : prédire un mot connaissant son environnement (cbow, « continuous bag of words »)
- ▶ algorithme alternatif : prédire un contexte à partir d'un mot (skip-gram)
- ▶ cbow fonctionne bien pour les mots fréquents, skip-gram pour les mots rares ;
- ▶ on a seulement besoin d'un corpus de textes.
- ▶ Structure du réseau : prédit le mot n en connaissant les mots $n - 2, n - 1, n + 1, n + 2$.
- ▶ les matrices H partagent les mêmes poids.


CBOW

Continuous Bag of Words




CBOW

- ▶ 4 vecteurs en entrées de taille v ,
taille du vocabulaire ;
- ▶ la dimension cachée h sera celle de
l'embedding final ;
- ▶ l'embedding est $H + M^T$
- ▶ pour l'indice i d'un mot du
vocabulaire V , l'embedding produit
un vecteur de dimension h .




SKIP-GRAM



Skip-Gram

- ▶ à partir du mot, on essaie de prédire $n = 4$ mots
- ▶ la fenêtre peut être plus large (d'où **skip-gram**);
- ▶ on peut considérer cela comme n tâches successives;
- ▶ apprend plus lentement que **CBOW**, mais fonctionne mieux avec mots rares.



« Distance » Cosinus

- ▶ soient v_1 et v_2 les vecteurs associés à deux mots ;
- ▶ norme euclidienne dépend trop de la fréquence des mots ;
- ▶ l'angle entre v_1 et v_2 est un bon critère ;
- ▶ en pratique, on utilise le cosinus de cet angle ;
- ▶ plus il est proche de 1, plus v_1 et v_2 sont proches ;
- ▶ calcul : $\frac{v_1 \cdot v_2}{|v_1||v_2|}$ (autrement dit $\frac{v_1^T v_2}{|v_1||v_2|}$)

Caractéristiques géométriques de l'embedding

Empiriquement, on constate :

- ▶ que les mots « proches » au sens du cosinus sont sémantiquement proches ;
- ▶ que la somme de plusieurs mots a un sens : « china + river = Yang Tse »
- ▶ qu'on peut travailler par analogie : « woman + (king - man) = queen »
- ▶ des phénomènes comme le pluriel, les contraires, le féminin, le superlatif sont représentés.

Glove

Global Vectors for Word Representation

Part des *propriétés souhaitées* sur les sommes et les différences de vecteurs ;

Si $P(a|b)$ est la probabilité de rencontrer le mot a dans le contexte du mot b , à votre avis :

1. $P(\text{solide}|\text{glace})/P(\text{solide}|\text{vapeur})$ est grand,
 $P(\text{gas}|\text{glace})/P(\text{gas}|\text{vapeur})$ est grand, et
 $P(\text{chat}|\text{ice})/P(\text{chat}|\text{vapeur})$ est proche de 0 ;
2. $P(\text{solide}|\text{glace})/P(\text{solide}|\text{vapeur})$ est proche de 1,
 $P(\text{gas}|\text{glace})/P(\text{gas}|\text{vapeur})$ est proche de 1, et
 $P(\text{chat}|\text{ice})/P(\text{chat}|\text{vapeur})$ est petit ;
3. $P(\text{solide}|\text{glace})/P(\text{solide}|\text{vapeur})$ est grand,
 $P(\text{gas}|\text{glace})/P(\text{gas}|\text{vapeur})$ est petit, et
 $P(\text{chat}|\text{ice})/P(\text{chat}|\text{vapeur})$ est proche de 1 ;

Glove

Global Vectors for Word Representation

	k = solid	k = gas	k = water	k = fashion
$P(k ice)$	$1.9 \cdot 10^{-4}$	$6.6 \cdot 10^{-5}$	$3 \cdot 10^{-3}$	$1.7 \cdot 10^{-5}$
$P(k steam)$	$2.2 \cdot 10^{-5}$	$7.8 \cdot 10^{-4}$	$2.2 \cdot 10^{-3}$	$1.8 \cdot 10^{-5}$
$P(k ice)/P(k steam)$	8.9	$8.5 \cdot 10^{-2}$	1.36	0.96

- ▶ idée : ce qui donne le sens des mots, ce sont les *rapports* entre les probabilités conditionnelles ;
- ▶ on définit la représentation w_i du mot i en essayant d'avoir une relation raisonnablement simple entre $w_i - w_j$, w_k , et $\frac{P(k|i)}{P(k|j)}$;
- ▶ les auteurs proposent *une* solution possible ;
- ▶ cette solution est calculée en minimisant une fonction de coût.
- ▶ cette solution est *globale* (pas de « fenêtre » comme dans word2vect) : capture mieux les informations **sémantiques** ;

- ▶ Similaire à Word2Vect
- ▶ Mais pour chaque mot on a dans le vecteur "one"-hot
 - ▶ une entrée pour le mot
 - ▶ une entrée pour chaque tri-gramme du mot
 - ▶ pour le mot *where*, on aura donc : <wh, whe, her, ere, re>, et where.
- ▶ (le vecteur n'est donc pas spécialement **one**-hot) ;
- ▶ plus robuste pour les mots inconnus ;
- ▶ capture aussi des informations de racine ;

Récapitulation sur l'embedding

- ▶ cbow fonctionne bien pour les mots fréquents, skip-gram pour les mots rares ;
- ▶ Glove fonctionne plutôt mieux que les deux précédents ;
- ▶ fasttext est plus robuste face aux mots inconnus ;

Représentation des mots caractère par caractère ?

- ▶ Représentation envisageable dans certains cas : le réseau « apprendra » sa propre notion de mot si nécessaire ;
- ▶ pas de problème de mots inconnus ;
- ▶ robustesse / fautes d'orthographe ;
- ▶ allonge l'entrée ; des problèmes liés à des mots proches (dans la phrase) deviennent des problèmes de dépendance à distance ;
- ▶ solution intermédiaire : découper le texte en syllabes ou en n-uplets de signes.

Bibliographie

Les livres un peu anciens (avant 2015 ?) ne contiennent presque rien sur le connexionnisme.

- ▶ Jurafsky, Daniel, et James H. Martin. *Speech and Language Processing*. 2 édition, 2008. ([Draft de la 3e édition, 2020](#))
- ▶ Eisenstein, Jacob. *Introduction to natural language processing. Adaptive computation and machine learning*. Cambridge, Massachusetts : The MIT Press, 2019. [preprint](#)
- ▶ Bird, Steven, Ewan Klein, et Edward Loper. *Natural Language Processing with Python*. O'Reilly, Inc., 2009. (inclus dans nltk)
- ▶ Mikolov, Tomas, Kai Chen, Greg Corrado, et Jeffrey Dean. « Efficient Estimation of Word Representations in Vector Space ». [arXiv :1301.3781](#) [cs], 2013
- ▶ Pennington, Jeffrey, Richard Socher, et Christopher D. Manning. « GloVe : Global vectors for word representation ». In *Empirical methods in natural language processing (EMNLP)*, 1532-43, 2014. [lien](#)

Webographie

- ▶ [Atala](#) : site de l'Association pour le Traitement Automatique des Langues
- ▶ [Computational Linguistics](#) revue internationale dans le domaine ;
- ▶ [nlpprogress](#) site listant l'état de l'art pour chaque type de problème classique ; donne aussi accès aux corpus de référence ;
- ▶ [NLP à Stanford](#) : site d'une des équipes les plus reconnues du domaine ;
- ▶ [Cours de Stanford 2020](#) archives complètes du cours 2020 (et des précédents)
- ▶ [CoreNLP](#) : bibliothèque de logiciels de stanford ;
- ▶ [Hugging Face](#) implémentations de la plupart des architectures classiques ;
- ▶ [Spacy](#) : une bibliothèque puissante et multilingue, mais peu adaptée à l'expérimentation architecturale ;