

TD Intelligence Artificielle n° 6

Processus décisionnels markoviens

Exercice 1 Parking de cinéma

On souhaite se garer au plus près d'un cinéma, afin de minimiser le temps de marche nécessaire pour y entrer (voir figure 1). Le parking attendant au cinéma est constitué d'une suite de n rangées parallèles : arrivé devant l'une d'entre elle, on peut décider soit d'essayer de s'y garer, soit de continuer à s'avancer. Si l'on essaye de se garer dans une rangée, on a 30 % de chance d'y trouver une place libre. En cas d'échec (70 % de chance), on est contraint de se rendre devant la rangée suivante. Si l'on n'a pas réussi à se garer dans le parking attendant, on doit obligatoirement se garer dans le parking extérieur, où il y a toujours de la place, mais qui ne se situe pas directement à côté. Le problème est de savoir, lorsque l'on arrive devant une rangée, s'il vaut mieux essayer de se garer, ou continuer à s'avancer.




FIGURE 1 – Représentation schématique du problème du parking. Les valeurs indiquées au dessus des rangées et pour le parking extérieur correspondent aux temps de marche pour rejoindre le cinéma (en minutes).

1. Définissez les états dans lesquels l'agent peut se trouver, les actions possibles dans chaque état, les probabilités de transition entre les états et les coûts moyens de la forme $c(s, a)$. Pour rappel : $c(s, a) = \sum_{s', c} P(s', c | s, a) c = \sum_{s'} P(s' | s, a) \sum_c P(c | s, a, s') c$. On utilisera notamment l'état spécial s_T pour la terminaison.
2. Représentez le problème sous forme de graphe.
3. Quel est le nombre d'étapes maximal ?
4. Appliquez l'algorithme de programmation dynamique à horizon majoré, en prenant $n = 5$.
5. Supposons que l'agent, initialement situé devant la cinquième rangée, suive la politique que vous venez de calculer. Détaillez sous forme d'arbre les déroulements possibles de l'épisode.

Exercice 2 Traitement contre le rhume

On considère le cas d'une personne sensible au froid, qui en hiver suit un traitement quotidien pour lutter contre le rhume. Au réveil, la personne peut se sentir bien (B) ou mal (M). En fonction de son état, elle doit choisir de prendre ou non un médicament (**med** ou **nil**) :

- si la personne se sent bien et qu'elle prend le médicament, elle aura 90 % de chance d'être dans le même état le lendemain,
- si la personne se sent bien et qu'elle ne prend pas le médicament, elle n'aura que 70 % de chance d'être dans le même état le lendemain,
- si la personne se sent mal et qu'elle prend le médicament, elle aura 80 % de chance d'aller mieux le lendemain,
- si la personne se sent mal et qu'elle ne prend pas le médicament, elle n'aura que 10 % de chance d'aller mieux.

Le médicament aide à aller mieux, mais a malheureusement très mauvais goût. La satisfaction de la personne à l'issue d'une décision se mesure de la manière suivante :

$$(1 \text{ si se sent bien le lendemain, } 0 \text{ sinon}) - (0,3 \text{ si a pris le médicament, } 0 \text{ sinon})$$

1. Définissez l'ensemble des états $\mathcal{S}$ et l'ensemble des actions $\mathcal{A}$. S'agit-il d'un processus stochastique ?
2. Représentez le problème (que l'on considérera à horizon infini) sous forme de graphe. Vous ferez notamment attention à écrire auprès des arcs le nom de chaque action, ainsi que la probabilité et la récompense (correspondant à la satisfaction) qui lui sont associées.
3. Calculez les récompenses moyennes de la forme $r(s, a)$ ($s \in \mathcal{S}$, $a \in \mathcal{A}$).
4. Appliquez l'algorithme d'itération sur les valeurs, en prenant $\epsilon = 0,6$.
5. Écrivez le système d'équations reliant les valeurs des états lorsque la personne suit la politique déterministe π que vous venez de calculer. On prendra $\gamma = 0,9$.
6. Donnez la valeur des états quand la personne suit la politique π . Il n'est pas nécessaire de fournir le calcul.

Exercice 3 Chauffeur de taxi

Un chauffeur de taxi travaille dans trois quartiers A, B et C. Ses courses peuvent l'amener à faire un trajet au sein d'un quartier, ou entre deux quartiers. Quand il doit trouver un nouveau client pour sa prochaine course, trois options s'offrent à lui. Il peut :

- a_1 : rouler dans le quartier actuel en espérant être hélé par un client,
- a_2 : s'arrêter à une station de taxis dans le quartier actuel et attendre un client,
- a_3 : stationner son taxi dans le quartier actuel et attendre un appel.

Dans les quartiers A et C, les trois actions sont possibles ; en revanche dans le quartier B, seules a_1 et a_3 sont possibles (il n'y a pas de station de taxis dans B). Les probabilités de transition et les récompenses en euros (p.ex. les bénéfices moyens attendus en fonction du quartier et de la méthode) sont fournies par le tableau 1.

P	action	quartier suivant			
		A	B	C	
quartier actuel	A	a_1	1/2	1/4	1/4
		a_2	1/16	3/4	3/16
		a_3	1/4	1/8	5/8
	B	a_1	1/2	0	1/2
		a_3	1/16	7/8	1/16
	C	a_1	1/4	1/4	1/2
		a_2	1/8	3/4	1/8
		a_3	3/4	1/16	3/16

	action	r	
quartier actuel	A	a_1	22
		a_2	14
		a_3	14
	B	a_1	32
		a_3	32
	C	a_1	20
a_2		12	
a_3		12	

TABLE 1 – Probabilités de transition (à gauche), et récompenses (à droite).

1. Quels sont les différents états du problème ?
2. Produisez le graphe des transitions partant de B uniquement.

3. Appliquez l'algorithme d'itération sur les politiques jusqu'à l'écriture du premier système d'équations linéaires, en prenant $\gamma = 0,8$. Pour l'initialisation, on utilisera la politique arbitraire suivante : $\forall s \in \mathcal{S}, \pi_0(s) = a_1$.
4. Ce système peut-être résolu de façon automatique, par exemple en Python avec la bibliothèque `numpy` :

```
>>> a = np.array([[-3/5, 1/5, 1/5], [2/5, -1, 2/5], [1/5, 1/5, -3/5]])
>>> b = np.array([-22, -32, -20])
>>> np.linalg.solve(a, b)
array([115.41666667, 123.33333333, 112.91666667])
```

Comment interpréter le résultat ?

Annexe

Algorithme 1 Programmation dynamique à horizon majoré

Entrée :

- $(\mathcal{S}, \mathcal{A}, P, r)$: un PDM fini, à horizon fini ou indéfini T
- m : un majorant de l'horizon ($T \leq m$)

Sortie : une politique déterministe non stationnaire optimale $\pi^* = (\pi_0^*, \dots, \pi_{m-1}^*)$

```
fonction progDynHorizonMajore( $\mathcal{S}, \mathcal{A}, P, r, m$ )  
   $v_0^* \leftarrow 0$  /* fonction de valeur optimale à horizon 0 */  
  pour  $h \leftarrow 0$  à  $m - 1$  faire  
    pour tout  $s \in \mathcal{S}$  faire  
      /* fonction de valeur optimale à horizon  $h + 1$  */  
       $v_{h+1}^*(s) \leftarrow \max_{a \in \mathcal{A}_s} \{r(s, a) + \sum_{s' \in \mathcal{S}} P(s'|s, a) v_h^*(s')\}$   
      /* politique optimale à l'instant  $t = m - 1 - h$  */  
       $\pi_{m-1-h}^* \leftarrow \arg \max_{a \in \mathcal{A}_s} \{r(s, a) + \sum_{s' \in \mathcal{S}} P(s'|s, a) v_h^*(s')\}$   
    fin pour  
  fin pour  
  retourner  $\pi^*$   
fin fonction
```

Remarques :

- Un PDM à horizon fini ou indéfini admet une étape finale, $t = T$. Dans le cas horizon fini, la valeur de T est fixée, tandis que dans le cas horizon indéfini, il s'agit d'une variable aléatoire.
- Le dernier état d'un PDM à horizon fini ou indéfini, s_T , est appelé *état terminal*. Il s'agit d'un état spécial, réservé à la terminaison, qui ne fait pas partie de $\mathcal{S}$ (on note parfois $\mathcal{S}^+ = \mathcal{S} \cup \{s_T\}$).
- L'algorithme 1 est aussi valide pour un PDM fini *non stationnaire*, à horizon fini ou indéfini. Il faut alors respectivement remplacer P et r par P_{m-1-h} et r_{m-1-h} , au sein de la boucle sur h .

Algorithme 2 Itération sur les valeurs

Entrée :

- $(\mathcal{S}, \mathcal{A}, P, r)$: un PDM fini et stationnaire
- γ : un facteur d'actualisation
- ϵ : un seuil d'erreur

Sortie : une politique déterministe proche de π^*

fonction `iterationSurValeurs`($\mathcal{S}, \mathcal{A}, P, r, \gamma, \epsilon$)
 initialiser arbitrairement $v' \in \mathbb{R}^{\mathcal{S}}$ */* v_0 */*
 répéter
 $v \leftarrow v'$
 pour tout $s \in \mathcal{S}$ **faire**
 / v_{i+1} définie à partir de v_i */*
 $v'(s) \leftarrow \max_{a \in \mathcal{A}_s} \{r(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s'|s, a)v(s')\}$
 fin pour
 jusqu'à $\|v' - v\|_{\infty} < \epsilon$
 $v \leftarrow v'$ */* v_k , proche de v^* */*
 pour tout $s \in \mathcal{S}$ **faire**
 $\pi(s) \leftarrow \arg \max_{a \in \mathcal{A}_s} \{r(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s'|s, a)v(s')\}$
 fin pour
 retourner π
fin fonction

Algorithme 3 Itération sur les politiques

Entrée :

- $(\mathcal{S}, \mathcal{A}, P, r)$: un PDM fini et stationnaire
- γ : un facteur d'actualisation

Sortie : une politique déterministe optimale π^*

fonction `iterationSurPolitiques`($\mathcal{S}, \mathcal{A}, P, r, \gamma$)
 initialiser arbitrairement $\pi'(s) \in \mathcal{A}_s$ pour tout $s \in \mathcal{S}$ */* π_0 */*
 répéter
 $\pi \leftarrow \pi'$
 / évaluation exacte de la politique :
 v_i est déterminée à partir de π_i (c.-à-d. $v_i = v_{\pi_i}$) */*
 résoudre le système de $|\mathcal{S}|$ équations linéaires à $|\mathcal{S}|$ inconnues

$$\begin{cases} \forall s \in \mathcal{S}, \\ v(s) = r(s, \pi(s)) + \gamma \sum_{s' \in \mathcal{S}} P(s'|s, \pi(s))v(s') \end{cases}$$

 / amélioration gloutonne de la politique :
 π_{i+1} est déterminée à partir de v_i */*
 pour tout $s \in \mathcal{S}$ **faire**
 $\pi'(s) \leftarrow \arg \max_{a \in \mathcal{A}_s} \{r(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s'|s, a)v(s')\}$
 fin pour
 jusqu'à $\pi' = \pi$
 retourner π */* π^* */*
fin fonction

Remarque : Dans des versions modifiées de l'algorithme 3, la politique n'est pas évaluée exactement (par résolution d'un système d'équations linéaires), mais de façon approchée, par exemple par calcul itératif (en suivant une procédure proche de celle de l'algorithme 2).