

TD Intelligence Artificielle n° 8

Rétropropagation

Exercice 1 Opérateurs et graphe de calcul

Le calcul réalisé par un réseau de neurones composé d'une multitude d'opérations élémentaires, dont l'organisation peut être interprétée sous forme de graphe. Dans les questions qui suivent, on représentera les graphes associés à des expressions, en faisant apparaître pour chaque opérateur les dérivées partielles de la sortie par rapport aux entrées.

1. Dessinez le graphe de calcul associé à $z = x + y$.
2. Dessinez le graphe de calcul associé à $z = x \times y$.
3. Dessinez le graphe de calcul associé à $z = \max(x, y)$.
4. Dessinez le graphe de calcul associé à $y = x + 1$. **Indication :** On ne représentera pas les constantes comme des entrées, mais comme faisant partie des opérateurs.
5. Considérons la fonction sigmoïde, $\sigma(z) = \frac{1}{1+e^{-z}}$, et remarquons la propriété suivante :

$$\frac{d\sigma(z)}{dz} = \frac{e^{-z}}{(1+e^{-z})^2} = \left(\frac{1+e^{-z}-1}{1+e^{-z}} \right) \left(\frac{1}{1+e^{-z}} \right) = (1-\sigma(z))\sigma(z)$$

Dessinez le graphe de calcul associé à $p = \sigma(z)$, en interprétant σ en tant qu'opérateur.

6. Dessinez le graphe de calcul associé à $b = 2 \times (u \times v + \max(x, y))$.
7. Sur ce dernier graphe, réalisez la propagation avant, puis la rétropropagation, en prenant $u = 3$, $v = -4$, $x = 2$ et $y = -1$.

Exercice 2 Rétropropagation dans un perceptron

On considère un perceptron pour la classification binaire (c.-à-d. $y = 1$ ou 0), dans le cas $\dim(\mathcal{X}) = 2$ (figure 1), dont la sortie (probabiliste) est :

$$p = P_{\theta}(Y = 1|X = x) = \sigma(z) = \frac{1}{1 + e^{-(w_0x_0 + w_1x_1 + b)}}$$

L'apprentissage des paramètres $\theta = (w_0, w_1, b)$ se fait par optimisation de la log-vraisemblance négative :

$$\begin{aligned} J_{\text{NLL}}(\theta, \mathcal{S}) &= \frac{1}{|\mathcal{S}|} \sum_{(x,y) \in \mathcal{S}} L_{\text{NLL}}(\theta, x, y) \\ L_{\text{NLL}}(\theta, x, y) &= -\log P_{\theta}(Y = y|X = x) \\ &= -(y \log(p) + (1-y) \log(1-p)) \\ &= \begin{cases} -\log(p) = -\log(P_{\theta}(Y = 1|X = x)) & \text{si } y = 1 \\ -\log(1-p) = -\log(P_{\theta}(Y = 0|X = x)) & \text{sinon} \end{cases} \end{aligned}$$

Et puisque

$$\frac{\partial J_{\text{NLL}}(\theta, \mathcal{S})}{\partial \theta} = \frac{1}{|\mathcal{S}|} \sum_{(x,y) \in \mathcal{S}} \frac{\partial L_{\text{NLL}}(\theta, x, y)}{\partial \theta}$$

on cherche à calculer, pour tout $(x, y) \in \mathcal{S}$, et pour tout paramètre θ_i :

$$\frac{\partial L_{\text{NLL}}(\theta, x, y)}{\partial \theta_i} = \frac{\partial -(y \log(p) + (1-y) \log(1-p))}{\partial \theta_i}$$




FIGURE 1 – Perceptron pour la classification binaire.

1. Dessinez le graphe de calcul associé à $L = -(y \log(p) + (1 - y) \log(1 - p))$.
2. Réalisez la rétropropagation sur ce graphe, afin d'exprimer $\frac{\partial L}{\partial p}$ en fonction de y et p .
3. Dessinez le graphe de calcul associé à $p = \sigma(w_0 x_0 + w_1 x_1 + b)$.
4. Poursuivez la rétropropagation sur ce graphe, afin d'exprimer $\frac{\partial L}{\partial w_0}$, $\frac{\partial L}{\partial w_1}$ et $\frac{\partial L}{\partial b}$ en fonction de x_0 , x_1 , y et p .
5. Écrivez la règle de mise à jour pour les différents paramètres, en supposant que l'on utilise un taux d'apprentissage α . Comparez avec l'algorithme du Perceptron.